

Consumo eléctrico por franja horaria, en streaming

Un pipeline end-to-end con Apache Kafka y Apache Beam sobre lecturas desordenadas, duplicadas y tardías

Proyecto integrador · Streaming de datos y sus aplicaciones
Maestría en Inteligencia Artificial, Facultad Politécnica – UNA · Prof. Rodrigo Parra, M.Sc.
Sergio Morel · Clara Almirón · Daniel Ramírez — septiembre de 2026

Resumen

△ PENDIENTE · *los tres, al final* — Media página. Qué problema se resuelve, qué se construyó y cuál es el resultado medible. Se escribe **último**, cuando los números ya están.

1. El problema y para quién

Una distribuidora eléctrica necesita **facturar a precio diferenciado según la hora**: no cuesta lo mismo un kWh en hora punta que de madrugada. Para eso hace falta saber cuánta energía consumió cada cliente **en cada franja**, y ahí empiezan las dificultades.

1.1 Por qué el dato no está disponible

Los medidores de este parque **no transmiten por su cuenta ni guardan una serie histórica**: responden con el valor actual de sus contadores cuando se les pregunta. Tres hechos de esa recolección determinan todo lo demás:

Hecho	Consecuencia
El registro 15.8.0 es un contador acumulado	El consumo no viene en el dato: se obtiene restando dos lecturas
Los medidores de una cabina comparten un bus RS-485 y se leen en secuencia	Ninguna lectura cae justo en el borde de una franja; la ronda dura de 6 a 60 minutos
El concentrador pierde enlace y publica después lo que juntó	Las lecturas llegan tardías, fuera de orden y en ráfagas

Hoy el sistema pide **una vez por día**, lo que alcanza para facturar el consumo diario y no para discriminar por franja. Habilitar la tarifa horaria exige pedir en cada borde, y ese es el cambio que este trabajo modela.

1.2 El giro: el tiempo de evento es dinero

En la mayoría de los pipelines, la distinción entre *tiempo de evento* y *tiempo de procesamiento* es una sutileza técnica. **Acá no**. Una lectura atribuida a la franja equivocada se factura a un precio equivocado, y el error no es aleatorio: se concentra en las cabinas grandes y de peor enlace, que son las que más tardan en completar una ronda.

Eso convierte una decisión de diseño en un requisito de negocio, y es la razón de que toda la política temporal del sistema esté justificada y no simplemente elegida.

1.3 Quién usa el resultado

Dos consumidores del mismo tópico, con necesidades opuestas:

	Tablero operativo	Facturación
Qué lee	Todos los panes de cada celda	Un solo valor por celda
Cuándo	Continuamente	Pasado <code>ventana_fin + 36 h</code>
Qué tolera	Que el número cambie mientras la ventana no converge	Nada: necesita un valor estable
Qué habilita	Ver la demanda por franja mientras el día transcurre	Emitir la factura con el precio correcto por franja

Esa diferencia es la que justifica el modo **acumulativo** con salida por *upsert*: cada pane es la revisión completa de la celda, así que el tablero puede mostrar el último y la facturación puede leer una sola vez sin reconstruir nada.


1.4 Qué mide el sistema, además del consumo

Un resultado que el trabajo produce y que no estaba en la consigna: **cada registro de salida declara su propio error de atribución**, derivado de la separación entre las dos lecturas que rodean el borde de la franja. El sistema no solo entrega un número, entrega cuánto se puede confiar en él — y eso permite cuantificar cuánto costaría, en dinero mal facturado, la arquitectura de recolección actual frente a una con un dispositivo por medidor.

2. Arquitectura

Consumo eléctrico por franja horaria — arquitectura

Proyecto integrador · Streaming de datos y sus aplicaciones · FPUNA. Flujo: concentrador → log crudo → pipeline → log derivado → consumidores.



El medidor entrega un contador acumulado (OBIS 15.8.0): el consumo no viene en el dato, se obtiene restando dos lecturas. Todos los datos son sintéticos.
Escenario B — un dispositivo de lectura por medidor, sin bus compartido — corre el MISMO pipeline y permite medir cuánto error elimina esa arquitectura.

Arquitectura del sistema: concentrador, log crudo, pipeline, log derivado y consumidores.

El flujo es **concentrador** → **log crudo** → **pipeline** → **log derivado** → **consumidores**, con una salida lateral a cuarentena. Cada componente está donde está por una razón:

El simulador ocupa el lugar del concentrador. Genera datos sintéticos y deterministas, y existe para **inyectar fallas a propósito**: pedidos que se corren, cabinas que caen enteras, tramas truncadas, duplicados y ráfagas tardías. Un simulador que se porta bien no sirve para demostrar que el pipeline tolera lo que tiene que tolerar.

Kafka en dos capas. El tópico crudo conserva las lecturas tal como llegaron, claveadas por medidor para que su orden se preserve — sin ese orden, la etapa de diferenciación no puede restar lecturas consecutivas. El tópico derivado lleva el resultado, claveado por la celda que identifica, de modo que recalculer reemplace en lugar de duplicar.

El pipeline sobre Beam y Flink hace cinco cosas en orden, y **el orden no es intercambiable**: la deduplicación va antes de la diferenciación porque, si no, un duplicado se restaría contra sí mismo y produciría un consumo de cero que, con salida por *upsert*, pisaría el valor correcto.

La cuarentena recibe todo lo que no se puede procesar, contado y con su motivo. Su volumen es una señal operativa: si sube en una zona, el problema es la cobertura de red y no el pipeline.

2.1 El detalle que condiciona el despliegue

KafkaIO no es una librería Python: es una transformación *cross-language* cuyas etapas de lectura y escritura ejecuta el SDK de **Java**. La imagen de Flink empaqueta los dos SDK y los corre en modo **PROCESS** dentro del TaskManager, lo que evita tener que darle al contenedor acceso al demonio de Docker. Está documentado en [infra/README.md](#).

3. Contrato de eventos y topología de Kafka

△ PENDIENTE · Clara — **es casi transcripción**: [contratos.md](#) §1 ya lo tiene resuelto

Lo que pide el enunciado: **contrato de eventos, tópicos, claves, particiones y esquema de salida**.

Lo que no puede faltar, porque son las decisiones que se defienden:

- Por qué `medidor_id` como clave y no `cabina_id` — el desbalance de 200× → [contratos.md](#) §1.2.
- Por qué 4 particiones, y por qué el criterio **no** es el throughput de escritura.
- La estrategia de evolución del esquema, que el enunciado pide explícitamente → §1.3.
- **La bandera de calidad que no significa corrupción** → §1.5. Es el hallazgo más fuerte que tenemos: descartar por esa bandera tiraría dos tercios de la muestra.

4. Tiempo de evento, ventanas y datos tardíos

△ PENDIENTE · Clara

Lo que pide el enunciado: **ventanas, lateness, y la política de datos tardíos**.

- Ventana diaria alineada al día local, y por qué la franja **no** es una ventana → decisión 6.
- Lateness de 36 h, con el razonamiento de por qué no 24 ni 48 → [contratos.md](#) §2.4.
- Triggers, panes y modo acumulativo, con lo que se resigna en el trigger tardío.
- **El error de atribución**, que es el resultado central: sale de la duración de la ronda, y la ronda la fija la tasa de fallas y no la velocidad → decisión 5.

5. Confiabilidad: duplicados, idempotencia y garantías

5.1 Dos reintentos que no producen lo mismo

Es la distinción de la que depende no descartar datos buenos:

Reintento	Qué produce	Quién lo maneja
De comunicación — se vuelve a pedir al medidor	Una lectura nueva , en un instante posterior. No es un duplicado	La lógica de franja, tolerando que la lectura no esté donde se la esperaba
De publicación — se vuelve a publicar a Kafka	Un duplicado real : mismo instante, mismo valor	La deduplicación

Tratar el primero como duplicado descartaría una medición legítima.

5.2 Deduplicación, y por qué va antes de diferenciar

Clave: (`medidor_id`, `instante_lectura`), que es exactamente lo que resume el `event_id` determinista. Horizonte: **36 horas**, el mismo que la lateness — si el estado expirara antes, un tardío legítimo volvería a parecer nuevo y se contaría dos veces.

El orden respecto de la diferenciación **no es intercambiable**:

- 1.ª vez: consumo = $R_2 - R_1$ ✓
- 2.ª vez: consumo = $R_2 - R_2 = 0$ ✗ y con `upsert`, ese 0 pisa el valor correcto

Hay una prueba con `TestStream` que fija este orden, de modo que nadie pueda invertirlo sin que la suite falle.

5.3 La salida idempotente

El pipeline **no puede evitar reintentar**: un timeout de escritura no dice si la escritura llegó. Por eso la idempotencia tiene que estar en la **forma de la salida** y no en no reintentar.

La clave `medidor|fecha|franja` identifica la **celda del resultado**, no el intento de escritura. Todos los panes de una celda comparten clave, van a la misma partición, se leen en orden y **el último gana**. Recalcular una ventana reemplaza su valor en lugar de sumar otro, y eso es lo que hace que el replay converja al mismo resultado.

5.4 Qué garantiza el sistema, y dónde termina

Declarado por tramo, sin sobreprometer:

Tramo	Garantía	Por qué
Concentrador → Kafka	Al menos una vez	El productor reintenta ante un fallo de publicación; puede duplicar
Dentro del pipeline	Efectivamente una vez dentro del horizonte de 36 h	Deduplicación con estado por clave, respaldada por el checkpointing de Flink
Pipeline → salida	Efectivamente una vez en el efecto observable	El <i>upsert</i> por clave estable hace que reescribir sea ino-cuo

No se afirma exactly-once de punta a punta, y conviene decir por qué: fuera del horizonte de 36 horas la deduplicación no garantiza nada, porque el estado ya expiró. Un duplicado que llegara al tercer día se contaría de nuevo. Es una decisión consciente — mantener el estado indefinidamente no es una opción sobre una entrada no acotada — y el límite queda declarado en lugar de escondido.

5.5 Un consumo negativo nunca es válido

En el mercado modelado no hay compra de energía al usuario, así que el contador solo puede subir. Una resta negativa es un **reseteo del equipo** o una **trama truncada**, nunca una medición: va a cuarentena.

Esa regla es además la segunda defensa contra el caso más peligroso del dominio — una trama cortada en medio de un número, que deja un valor plausible que ninguna validación de formato detecta.

6. Pruebas y evidencia

△ PENDIENTE · los tres

Lo que pide el enunciado: **pruebas de lógica y de tiempo, escenarios adversos, y demostración del recorrido completo**.

- Pruebas unitarias: 34 del simulador, 23 de franjas.
- Pruebas con `TestStream`: duplicado, tardío dentro de tolerancia, tardío fuera, desorden.
- **La prueba de humo**, que recorre simulador → Kafka → Beam → Kafka → [infra/README.md](#).
- **El contraste A/B**: el mismo pipeline, sin cambiar una línea, contra las dos arquitecturas de recolección. Convierte el error de atribución de estimación en medición.

7. Límites, supuestos y posibles mejoras

7.1 Supuestos declarados

Supuesto	En qué se apoya
No hay compra de energía al usuario	Es un rasgo del marco regulatorio modelado, no una simplificación nuestra. Sin inyección remunerada, 15.8.0 equivale a energía consumida
Un consumo negativo es siempre un reseteo	Se desprende del anterior: sin exportación, el contador no baja
No rige horario de verano	Evita días con franjas de duración distinta. Si volviera, la configuración tendría que contemplarlos
Ningún medidor acumula por franja	No es una simplificación: es incompatible con que las franjas sean configurables, porque un cambio de calendario obligaría a reconfigurar el parque en campo

7.2 Límites conocidos

La tasa de fallas no está calibrada. Las mediciones disponibles muestran la *forma* de cada caso —la distribución de duraciones es trimodal, la escalera de reintentos es determinista— pero **no permiten estimar con qué frecuencia** ocurre cada uno. Es el parámetro más influyente del modelo, y el error de atribución que el sistema reporta depende de él.

La correlación por modelo de equipo es invisible para este pipeline. Con el mismo enlace, las tasas de entrega por modelo van de 65 % a 94 %, y como los modelos están repartidos por todo el parque esa correlación es **espacialmente dispersa**: ninguna partición por ubicación la aísla. Un pipeline particionado por medidor o por cabina no puede verla. Es el límite más interesante que encontramos, porque hay una estructura real en los datos que la clave de particionamiento elegida no alcanza.

Un evento perdido arruina dos intervalos, no uno. Si falta la lectura de las 18:15, no se puede calcular el consumo de 18:00–18:15 *ni* el de 18:15–18:30: el primero pierde su final y el segundo su inicio.

Un pane por evento tardío. La ráfaga de una cabina que vuelve de una caída produce una escritura por lectura. En producción convendría agrupar los disparos tardíos, a costa de demorar la corrección unos minutos — algo que a la facturación no le cambia nada. Se eligió la versión por evento **para que la corrección sea visible en la demostración**.

Fuera de las 36 horas no hay deduplicación, como se explica en §5.4.

7.3 Posibles mejoras

Un dispositivo de lectura por medidor. Elimina de raíz la limitación de fondo, que es el bus compartido. Y su justificación económica **sale de este mismo trabajo**: el error de atribución que el pipeline mide hoy es exactamente lo que esa inversión ahorraría. El simulador genera ese escenario y el **mismo pipeline, sin cambios**, lo procesa — así la comparación es una medición y no una estimación.

Si se hace, conviene que el dispositivo exponga sus parciales en **códigos OBIS propios** y no en los registros tarifarios estándar: permite leer el total del medidor y los parciales del dispositivo y **verificar que sumen**, de modo que un dispositivo desincronizado se detecte solo.

Reducir la pausa entre medidores. Un tercio del tiempo por medidor es una pausa fija que el concentrador aplica, y es una decisión de implementación, no del protocolo. Es el parámetro más barato de mejorar de todos los que aparecen en este análisis.

Medición neta. Si se introdujera compra de energía al usuario, habría que leer **1.8.0** y **2.8.0** por separado y la regla del consumo negativo dejaría de valer.

Una materialización intermedia para el tablero, si alguna vez hacen falta consultas ad-hoc o muchos lectores concurrentes.

8. Integrantes y contribuciones

△ PENDIENTE · los tres

Lo que pide el enunciado: **lista de integrantes y contribuciones principales de cada persona.**

Integrante	Contribución principal
Sergio Morel	△ completar
Clara Almirón	△ completar
Daniel Ramírez	△ completar

El historial de git lo respalda: `git shortlog -sn --no-merges`.